DUOC UC

Escuela de Informática y Telecomunicaciones — Ingeniería en Informática

ANTEPROYECTO DE TÍTULO

Control adaptativo de semáforos mediante aprendizaje por refuerzo multi-agente

Evaluación comparativa frente a estrategias clásicas de control en un corredor urbano de Santiago de Chile

Autor: Gabriel Ignacio Cárdenas Valdés

Profesor guía: _____

Santiago de Chile — 2026

Índice

Al abrir el documento en Word, actualizar este índice con clic derecho sobre él → Actualizar campos → Actualizar toda la tabla.

Resumen ejecutivo

La congestión vehicular en las grandes ciudades es, en buena medida, un problema de coordinación: la infraestructura existe, pero el reparto del tiempo verde entre movimientos que compiten por la misma intersección responde a planes fijos o semi-adaptativos que no se ajustan con la rapidez suficiente a la demanda real. Este anteproyecto propone diseñar, implementar y evaluar un sistema de control adaptativo de semáforos basado en aprendizaje por refuerzo multi-agente (MARL), y contrastarlo de manera rigurosa contra las estrategias de control clásicas que hoy constituyen el estado de la práctica.

El trabajo se desarrollará íntegramente sobre simulación microscópica en SUMO, usando como escenario un corredor real de Santiago de Chile reconstruido desde OpenStreetMap y calibrado con datos públicos de demanda. La contribución esperada no es un nuevo algoritmo de aprendizaje profundo, sino evidencia experimental reproducible sobre cuánto margen de mejora ofrece el control aprendido frente al control clásico bien sintonizado, en una red urbana latinoamericana concreta y bajo condiciones de demanda realistas.

Enfoque seleccionado: evaluación comparativa (planes de tiempo fijo, Webster y Max-Pressure como líneas base) contra un agente MARL con entrenamiento centralizado y ejecución descentralizada. Este diseño garantiza resultados medibles aun si el agente aprendido no supera a los baselines, lo que elimina el riesgo principal de una tesis basada exclusivamente en aprendizaje profundo.

1. Planteamiento del problema

1.1 Contexto

El control de semáforos en las ciudades chilenas está a cargo de la Unidad Operativa de Control de Tránsito (UOCT), organismo dependiente del Ministerio de Transportes y Telecomunicaciones creado en 1990, con cobertura en nueve regiones del país y sede nacional en Providencia, Santiago. La UOCT monitorea en tiempo real la operación de la mayoría de los semáforos de las ciudades bajo su gestión mediante una red de comunicaciones dedicada, y opera sobre plataformas de control centralizado de tipo UTC/SCATS.

Estos sistemas representan un avance sustantivo respecto del control de tiempo fijo: ajustan duración de ciclo, reparto de verdes y desfases entre intersecciones a partir de mediciones de lazos detectores. Sin embargo, operan dentro de un espacio de planes predefinidos y con lógicas heurísticas diseñadas décadas atrás, lo que limita su capacidad de reaccionar a patrones de demanda que se desvían de los históricos: cortes de calles, eventos masivos, incidentes o cambios estructurales en la partición modal.

1.2 Problema de investigación

El problema abordado es el siguiente: los esquemas de control de semáforos actualmente desplegados asignan tiempo verde a partir de reglas fijas o de un catálogo acotado de planes, y por lo tanto no explotan toda la información disponible sobre el estado instantáneo de la red. Esto se traduce en demoras evitables, colas que se propagan aguas arriba y, en casos extremos, bloqueo de intersecciones.

La literatura reciente sostiene que un controlador que aprende una política de conmutación de fases directamente desde el estado observado de la red puede superar a los esquemas clásicos, pero la evidencia proviene mayoritariamente de redes sintéticas o de escenarios calibrados sobre ciudades europeas y chinas. No existe evidencia sistemática y reproducible sobre el desempeño relativo de estas técnicas en la geometría vial, la composición del parque vehicular y los patrones de demanda característicos de Santiago de Chile.

1.3 Preguntas de investigación

1. **PI1.** ¿Qué mejora porcentual en demora media por vehículo y en tiempo de viaje logra un controlador basado en aprendizaje por refuerzo multi-agente frente a planes de tiempo fijo, Webster y Max-Pressure, sobre un corredor real de Santiago?
2. **PI2.** ¿Cómo varía esa ventaja según el nivel de demanda (valle, punta mañana, punta tarde y demanda sobresaturada)?
3. **PI3.** ¿Qué esquema de coordinación entre agentes (aprendizaje independiente, entrenamiento centralizado con ejecución descentralizada, o comunicación basada en grafos) ofrece el mejor compromiso entre desempeño y costo computacional para una red de escala media?
4. **PI4.** ¿Qué robustez presenta la política aprendida ante perturbaciones no vistas en entrenamiento, como el cierre de un carril o un aumento repentino de la demanda?

1.4 Justificación

- **Relevancia social y económica.** La congestión impone costos directos en tiempo de viaje, consumo de combustible y emisiones. Una mejora marginal en el reparto de verdes, replicada sobre cientos de intersecciones, tiene un impacto agregado no despreciable y no requiere obra civil.
- **Relevancia técnica.** El control adaptativo aprendido es un caso de estudio canónico de sistemas multi-agente con observabilidad parcial, y permite ejercitar de forma integrada simulación, ingeniería de datos, aprendizaje profundo y diseño experimental.
- **Vacío identificado.** Los benchmarks de referencia del área utilizan escenarios de Hangzhou, Jinan, Colonia e Ingolstadt. Aportar un escenario santiaguino calibrado y publicado abre la puerta a comparaciones futuras y constituye en sí mismo un artefacto reutilizable.
- **Factibilidad.** Todo el trabajo se realiza en simulación, con herramientas de código abierto y sin necesidad de convenios institucionales ni de intervención sobre infraestructura real.

2. Objetivos e hipótesis

2.1 Objetivo general

Diseñar, implementar y evaluar experimentalmente un sistema de control adaptativo de semáforos basado en aprendizaje por refuerzo multi-agente, cuantificando su desempeño frente a estrategias de control clásicas sobre un corredor urbano real de Santiago de Chile simulado en SUMO.

2.2 Objetivos específicos

Cada objetivo específico se formula de modo verificable y con un producto asociado.

N.°	Objetivo específico	Producto verificable
OE1	Construir y calibrar un escenario de simulación microscópica de un corredor de Santiago con al menos ocho intersecciones semaforizadas, a partir de datos de OpenStreetMap y de fuentes públicas de demanda.	Red SUMO (.net.xml), matriz de demanda y archivos de ruta versionados en el repositorio, con reporte de calibración.
OE2	Implementar tres controladores de referencia: plan de tiempo fijo, plan optimizado según el método de Webster y controlador Max-Pressure.	Módulos de control ejecutables y reproducibles, con pruebas unitarias sobre la lógica de conmutación de fases.
OE3	Formular el control de la red como un problema de decisión de Markov descentralizado, definiendo espacio de observación, espacio de acción y función de recompensa por intersección.	Especificación formal documentada e implementada como entorno compatible con PettingZoo.
OE4	Entrenar y ajustar al menos dos configuraciones de agentes MARL (aprendizaje independiente y entrenamiento centralizado con ejecución descentralizada).	Políticas entrenadas, curvas de aprendizaje y registro de hiperparámetros.
OE5	Evaluar comparativamente todos los controladores bajo escenarios de demanda diferenciados, con réplicas independientes y análisis estadístico de significancia.	Protocolo experimental, tablas de resultados con intervalos de confianza y pruebas de hipótesis.
OE6	Analizar la robustez de la política aprendida ante perturbaciones no presentes en el entrenamiento.	Batería de escenarios de perturbación y análisis de degradación del desempeño.
OE7	Documentar hallazgos, limitaciones y condiciones bajo las cuales el enfoque aprendido resulta o no ventajoso.	Informe final de tesis y repositorio reproducible.

2.3 Hipótesis

H1. Un controlador basado en aprendizaje por refuerzo multi-agente reduce la demora media por vehículo en al menos un 10 % respecto de un plan de tiempo fijo optimizado con el método de Webster, bajo condiciones de demanda de hora punta, con significancia estadística al 95 %.

H2. La ventaja del controlador aprendido sobre Max-Pressure es menor que su ventaja sobre el tiempo fijo, y se concentra en regímenes de demanda cercanos a la saturación.

H3. Los esquemas de entrenamiento centralizado con ejecución descentralizada superan al aprendizaje independiente en métricas de red, a costa de un mayor tiempo de entrenamiento.

Nota metodológica: el umbral del 10 % en H1 es una hipótesis a contrastar, no un resultado comprometido. Un resultado negativo bien fundamentado (por ejemplo, que Max-Pressure iguale al agente aprendido con una fracción del costo computacional) constituye un hallazgo válido y publicable, y así se declara desde el diseño.

3. Marco teórico y estado del arte

3.1 Fundamentos del control de intersecciones semaforizadas

Una intersección semaforizada reparte un recurso escaso —el derecho de paso— entre movimientos incompatibles. Los conceptos operativos centrales son la fase (conjunto de movimientos que reciben verde simultáneamente), el ciclo (tiempo que toma recorrer todas las fases), el reparto o split (fracción del ciclo asignada a cada fase), el desfase u offset (corrimiento temporal entre intersecciones vecinas) y el tiempo perdido asociado a los intervalos de ámbar y rojo total.

3.1.1 Control de tiempo fijo y método de Webster

El control de tiempo fijo aplica un plan invariante derivado de aforos históricos. La formulación clásica de Webster (1958) entrega la duración de ciclo que minimiza la demora total en función del tiempo perdido por ciclo y de los grados de saturación de cada fase, junto con un reparto proporcional a dichos grados. Es un método analítico, barato y sorprendentemente competitivo cuando la demanda es estable, razón por la cual constituye una línea base obligatoria.

3.1.2 Control actuado y adaptativo desplegado

Los sistemas actuados extienden el verde mientras los detectores registran demanda continua. Los sistemas centralizados de tipo UTC —SCATS y SCOOT, entre otros— seleccionan o interpolan planes en función de mediciones agregadas y coordinan desfases a lo largo de corredores. Esta familia es la que opera en Chile bajo la administración de la UOCT y define el estado de la práctica contra el cual debe medirse cualquier propuesta.

3.1.3 Max-Pressure

Max-Pressure, formalizado por Varaiya (2013) a partir de resultados de control de redes de colas, selecciona en cada instante de decisión la fase que maximiza la diferencia entre las colas aguas arriba y aguas abajo de los movimientos habilitados. Su atractivo es doble: es descentralizado —cada intersección decide con información local— y cuenta con una garantía teórica de estabilidad, en el sentido de maximizar la región de demandas para las cuales las colas permanecen acotadas. Sus limitaciones prácticas conocidas incluyen el supuesto de colas ilimitadas aguas abajo, la ausencia de coordinación explícita de progresión y la penalización insuficiente de los cambios frecuentes de fase, aspecto abordado por trabajos posteriores que incorporan la pérdida por conmutación.

3.2 Aprendizaje por refuerzo aplicado al control de semáforos

El control de una intersección se modela naturalmente como un proceso de decisión de Markov: el agente observa un estado (densidades y colas por carril, fase actual, tiempo transcurrido en la fase), escoge una acción (mantener la fase o conmutar a otra fase del conjunto admisible) y recibe una recompensa que penaliza demora, colas o detenciones. Los algoritmos de valor tipo DQN (Mnih et al., 2015) y de política tipo PPO (Schulman et al., 2017) son los más utilizados en el área.

Cuando el problema se extiende a una red, aparece la dimensión multi-agente. La literatura reciente organiza las soluciones en tres familias:

- **Aprendizaje independiente (DTDE).** Cada intersección entrena su propia política con observación local y sin comunicación. Es simple y escala linealmente, pero sufre de no estacionariedad: desde la perspectiva de cada agente, el entorno cambia cuando los demás aprenden.
- **Entrenamiento centralizado, ejecución descentralizada (CTDE).** Métodos como QMIX, VDN, MADDPG o MAPPO utilizan información global durante el entrenamiento —una función de valor conjunta o un crítico centralizado— pero cada agente ejecuta con información local. Mitiga la no estacionariedad y el problema de asignación de crédito.
- **Métodos basados en grafos y comunicación.** PressLight (Wei et al., 2019) incorpora la noción de presión de Max-Pressure en la función de recompensa del agente aprendido; CoLight (Wei et al., 2019) usa atención sobre el grafo de vecindad para que cada intersección pondere la influencia de sus vecinas. Son el estado del arte en desempeño de red, con mayor costo de implementación.

3.3 Simuladores y benchmarks

SUMO (Simulation of Urban MObility), desarrollado por el DLR alemán, es el simulador microscópico de código abierto más utilizado en investigación de control de semáforos; expone la interfaz TraCI/libsumo para control en línea. Sobre él se han construido entornos estandarizados de aprendizaje: sumo-rl expone la simulación como entorno Gymnasium (agente único) y PettingZoo (multi-agente), con observación por defecto compuesta por codificación one-hot de la fase, indicador de verde mínimo, densidad y cola por carril, y recompensa basada en la variación de la demora acumulada; es compatible con Stable-Baselines3 y RLlib y se distribuye bajo licencia MIT. RESCO (Ault y Sharon, 2021) provee un conjunto de escenarios y líneas base estandarizadas para comparación reproducible, incluyendo redes calibradas de Colonia e Ingolstadt.

3.4 Brechas identificadas

Las revisiones sistemáticas recientes del área (por ejemplo, Donatus et al., 2025) coinciden en señalar como desafíos abiertos la escalabilidad ante el crecimiento exponencial del espacio conjunto de estados y acciones, la no estacionariedad del aprendizaje simultáneo, la asignación de crédito individual sobre objetivos colectivos, la transferencia de simulación a infraestructura real y el diseño de funciones de recompensa. A ello se suma, desde la perspectiva de esta tesis, una brecha geográfica: la escasez de escenarios calibrados y de resultados comparativos publicados sobre redes latinoamericanas.

4. Selección del enfoque técnico

Se evaluaron tres alternativas de enfoque antes de fijar la metodología. El criterio de decisión combina valor académico del aporte, riesgo de no obtener resultados y ajuste a la disponibilidad de tiempo declarada (aproximadamente seis meses con dedicación parcial, del orden de 240 horas efectivas).

Alternativa	Fortalezas	Riesgos	Ajuste al proyecto
A. MARL puro como único aporte	Máximo valor académico. Alineado con la frontera del área.	Si el agente no supera a los baselines, la tesis queda sin resultado. Entrenamiento costoso y sensible a hiperparámetros.	Alto riesgo para un plazo acotado y sin cluster de cómputo.
B. Algoritmos clásicos y metaheurísticas	Implementación directa. Resultados garantizados. Fácil de defender.	Aporte incremental bajo. Terreno muy explorado desde los años 60.	Bajo riesgo, pero también bajo valor diferenciador.
C. Comparativa rigurosa clásicos vs. MARL	Resultados asegurados por los baselines. El agente MARL aporta la componente de innovación. El escenario calibrado es un artefacto reutilizable.	Mayor volumen de implementación. Exige disciplina en el diseño experimental.	Ajuste adecuado: el riesgo se concentra en una componente y no compromete la tesis completa.

Enfoque adoptado: alternativa C. El núcleo del aporte es el agente MARL con coordinación CTDE, pero el diseño se estructura de modo que las líneas base clásicas —tiempo fijo, Webster y Max-Pressure— sean resultados de primera clase y no meros puntos de comparación. Si el agente aprendido supera a los baselines, la tesis reporta una mejora cuantificada sobre una red santiaguina real; si no lo hace, reporta bajo qué condiciones el control clásico bien sintonizado sigue siendo competitivo, lo cual es un hallazgo igualmente valioso y menos frecuente en la literatura publicada.

5. Metodología

5.1 Tipo de investigación

Investigación aplicada, de carácter cuantitativo y experimental, con diseño comparativo de tratamientos (controladores) sobre un mismo entorno simulado, con réplicas independientes y control de variables exógenas mediante semillas aleatorias fijadas.

5.2 Escenario de simulación

Se trabajará sobre un corredor arterial real de Santiago con entre ocho y doce intersecciones semaforizadas consecutivas —se evaluarán como candidatos los ejes Providencia–Apoquindo y Vicuña Mackenna—, seleccionado según tres criterios: densidad de intersecciones semaforizadas, disponibilidad de información pública de demanda y presencia de congestión recurrente documentada.

5.2.1 Construcción de la red

1. Extracción de la geometría vial desde OpenStreetMap y conversión a formato SUMO mediante netconvert / osmWebWizard.
2. Depuración manual en netedit: corrección de conectividad, número de carriles, movimientos permitidos, prioridades y geometría de las intersecciones.
3. Definición de programas semafóricos base a partir de la estructura de fases observable en terreno o en imágenes satelitales y de calle.
4. Verificación de que la red simula sin bloqueos ni advertencias de teletransporte bajo demanda baja.

5.2.2 Demanda vehicular

La demanda se construirá en dos capas. La primera es una estimación de flujos por acceso a partir de fuentes públicas: la Encuesta Origen Destino de Viajes del Gran Santiago publicada por SECTRA, los conjuntos de datos de movilidad del portal de datos abiertos del Estado y los antecedentes de aforos disponibles. La segunda es un ajuste iterativo mediante las herramientas de calibración de SUMO, de modo que los flujos simulados en secciones de control reproduzcan los volúmenes de referencia dentro de una tolerancia declarada.

Advertencia de factibilidad: la disponibilidad de aforos direccionales por intersección para Santiago no está garantizada al inicio del proyecto. El plan de contingencia consiste en calibrar contra volúmenes agregados por eje y declarar explícitamente el nivel de fidelidad alcanzado; el diseño comparativo sigue siendo válido, porque todos los controladores se enfrentan a la misma demanda.

Se definirán cuatro perfiles de demanda: valle, punta mañana, punta tarde y un escenario de sobresaturación construido escalando la punta más alta, destinado a estresar los controladores fuera del régimen para el que fueron sintonizados.

5.3 Formulación del problema de aprendizaje

Componente	Definición propuesta
Agentes	Un agente por intersección semaforizada. Se explorará adicionalmente el agrupamiento de intersecciones muy cercanas en un agente único.
Observación	Por agente: codificación one-hot de la fase activa, tiempo transcurrido en la fase, indicador de verde mínimo cumplido, densidad de ocupación y longitud de cola por carril de aproximación. Variante extendida: agregado de las colas de las intersecciones vecinas inmediatas.
Acción	Espacio discreto sobre el conjunto de fases admisibles: elegir la próxima fase verde cada intervalo de decisión (valor inicial 5 s), con inserción automática de ámbar y rojo total al conmutar, y respeto de verde mínimo y máximo.
Recompensa	Línea base: variación negativa de la demora acumulada entre pasos de decisión. Variantes a evaluar: presión de la intersección en el sentido de Max-Pressure, y una combinación penalizada por número de conmutaciones.
Restricciones de seguridad	Verde mínimo, verde máximo, secuencia de fases admisible y tiempos de despeje se imponen como restricciones duras del entorno, no como penalizaciones aprendidas.

5.4 Controladores a implementar

Controlador	Tipo	Rol en el experimento
FIXED	Tiempo fijo con el plan base de la red.	Piso de comparación; representa la operación no optimizada.
WEBSTER	Tiempo fijo con ciclo y repartos calculados por el método de Webster para cada perfil de demanda.	Línea base fuerte y justa: es lo mínimo que un ingeniero de tránsito haría.
MAXPRESSURE	Descentralizado, sin aprendizaje, con garantía teórica de estabilidad.	Estado del arte no aprendido; la comparación más exigente.
IQL / IPPO	MARL con aprendizaje independiente por intersección.	Establece cuánto aporta el aprendizaje sin coordinación explícita.
MAPPO (CTDE)	MARL con crítico centralizado y ejecución descentralizada.	Configuración principal del aporte de la tesis.

5.5 Métricas de evaluación

- **Primarias:** demora media por vehículo (s), tiempo de viaje medio (s) y tiempo de espera total en la red.
- **Secundarias:** longitud media y máxima de cola por acceso, throughput (vehículos que completan su ruta por hora), número medio de detenciones por vehículo y velocidad media de recorrido.
- **Externalidades:** consumo de combustible y emisiones de CO_2 y NOx, estimadas con los modelos HBEFA incorporados en SUMO.

- **Equidad:** percentil 95 del tiempo de espera, para detectar políticas que optimizan el promedio a costa de penalizar sistemáticamente los movimientos menores.
- **Costo:** tiempo de entrenamiento, número de pasos de simulación consumidos y tiempo de inferencia por decisión.

5.6 Diseño experimental

1. Cada combinación de controlador y perfil de demanda se ejecuta con al menos treinta semillas aleatorias independientes, idénticas entre controladores para permitir comparación pareada.
2. Se descarta un período de calentamiento inicial de la simulación antes de comenzar a registrar métricas.
3. Los agentes se entrenan sobre un conjunto de semillas y se evalúan sobre un conjunto disjunto, para evitar sobreajuste al escenario concreto.
4. Las diferencias entre controladores se contrastan con pruebas no paramétricas (Wilcoxon para muestras pareadas), reportando tamaño de efecto e intervalos de confianza al 95 %, y no solamente el valor p.
5. Todos los experimentos se ejecutan mediante scripts parametrizados, con semillas, versiones e hiperparámetros registrados, de modo que cualquier tabla del informe pueda regenerarse desde el repositorio.

5.7 Pruebas de robustez

Sobre la mejor política aprendida se aplicarán perturbaciones no vistas durante el entrenamiento: cierre de un carril en un tramo del corredor, incremento súbito del 30 % en la demanda de un acceso, falla simulada de un detector con observación degradada, e inserción de vehículos pesados o de transporte público con paradas. Se reportará la degradación relativa del desempeño frente a Max-Pressure bajo las mismas perturbaciones.

5.8 Stack tecnológico

Componente	Herramienta
Simulación microscópica	SUMO (Eclipse), con libsumo para acelerar el entrenamiento.
Entorno de aprendizaje	sumo-rl (interfaces Gymnasium y PettingZoo, licencia MIT).
Algoritmos de RL	Stable-Baselines3 y Ray RLlib para las variantes multi-agente.
Lenguaje y análisis	Python 3.11+, NumPy, pandas, SciPy, Matplotlib.
Seguimiento de experimentos	MLflow o Weights & Biases para registro de corridas e hiperparámetros.
Control de versiones	Git, con el escenario, el código y los scripts de análisis en un único repositorio.
Cómputo	Estación local para desarrollo; entrenamiento en instancias con GPU bajo demanda si el costo lo justifica.

6. Alcance y limitaciones

6.1 Dentro del alcance

- Construcción y calibración de un escenario de simulación de un corredor real de Santiago.
- Implementación de tres controladores clásicos y al menos dos configuraciones de agentes MARL.
- Evaluación comparativa cuantitativa con análisis estadístico y pruebas de robustez.
- Repositorio reproducible con escenario, código, configuraciones y scripts de análisis.

6.2 Fuera del alcance

- Despliegue en infraestructura real o integración con los sistemas operativos de la UOCT.
- Control de vehículos conectados o autónomos; se asume una flota convencional conducida por personas.
- Optimización conjunta con otros modos de gestión (tarificación vial, gestión de estacionamientos, prioridad activa de buses más allá de su modelamiento como vehículos).
- Modelamiento detallado del comportamiento peatonal más allá de las fases peatonales necesarias para la validez del plan.
- Predicción de demanda a partir de datos históricos como línea de investigación independiente.

6.3 Limitaciones reconocidas

- **Brecha simulación–realidad.** Los resultados son válidos dentro del modelo de simulación. La transferencia a operación real requiere validación adicional que excede este trabajo y así se declarará en las conclusiones.
- **Calidad de la calibración.** La fidelidad del escenario está acotada por la granularidad de los datos públicos disponibles.
- **Escala.** Un corredor de ocho a doce intersecciones no permite extrapolar directamente a la red completa de Santiago, que involucra miles de intersecciones.
- **Supuesto de observabilidad.** Se asume disponibilidad de mediciones de cola y densidad por carril, superior a la instrumentación de lazos actualmente desplegada. Se incluirá al menos un experimento con observación degradada para dimensionar el efecto de este supuesto.

7. Plan de trabajo y cronograma

El plan considera seis meses de trabajo con una dedicación aproximada de diez horas semanales, equivalente a unas 240 horas efectivas. Se organiza en hitos verificables, cada uno con un entregable que permite al profesor guía evaluar avance sin depender de la percepción del autor.

Mes	Fase	Actividades principales	Entregable / hito
1	Fundamentos y escenario	Revisión bibliográfica dirigida. Instalación del stack. Selección del corredor. Importación desde OSM y depuración de la red.	H1: Red SUMO funcional que simula sin errores + matriz bibliográfica.
2	Demanda y líneas base	Recolección de datos de demanda. Calibración de flujos. Implementación de FIXED y WEBSTER.	H2: Escenario calibrado y dos baselines operativos con métricas reportadas.
3	Max-Pressure y entorno RL	Implementación y verificación de Max-Pressure. Formulación del Dec-POMDP. Integración con sumo-rl y PettingZoo.	H3: Los tres baselines comparados + entorno RL que entrena un agente de prueba.
4	Entrenamiento MARL	Entrenamiento de IQL/IPPO. Búsqueda de hiperparámetros. Ajuste de la función de recompensa.	H4: Primera política aprendida con curvas de aprendizaje estables.
5	CTDE y experimentación	Implementación de MAPPO. Ejecución de la batería experimental completa con réplicas. Pruebas de robustez.	H5: Tablas de resultados completas con análisis estadístico.
6	Análisis y redacción	Análisis e interpretación. Redacción del informe final. Limpieza del repositorio. Preparación de la defensa.	H6: Informe final, repositorio reproducible y presentación.

Regla de corte: si al término del mes 4 no se dispone de una política aprendida que al menos iguale al plan de tiempo fijo, se congela la exploración de arquitecturas y se redirige el esfuerzo hacia la profundización del análisis comparativo entre los controladores clásicos y las variantes de recompensa. Esto protege la entrega del informe frente al riesgo principal del proyecto.

8. Análisis de riesgos

Riesgo	Prob.	Impacto	Mitigación
No se obtienen datos de demanda con granularidad suficiente para el corredor elegido.	Alta	Medio	Calibrar con volúmenes agregados y declarar el nivel de fidelidad. El diseño comparativo permanece válido porque todos los controladores enfrentan la misma demanda.
El entrenamiento MARL no converge o resulta inestable.	Media	Alto	Partir de una sola intersección antes de escalar; reutilizar hiperparámetros publicados en sumo-rl y RESCO; aplicar la regla de corte del mes 4.
Costo computacional del entrenamiento superior al previsto.	Media	Medio	Usar libsumo en lugar de TraCI (aceleración cercana a un orden de magnitud); reducir la resolución temporal de decisión; acotar el número de intersecciones.
La red importada desde OSM presenta errores de conectividad difíciles de depurar.	Media	Medio	Reservar tiempo explícito de depuración en netedit durante el mes 1; considerar un corredor alternativo más simple como respaldo.
El agente aprendido no supera a Max-Pressure.	Media	Bajo	Está contemplado en el diseño: se reporta como hallazgo, con análisis de las condiciones bajo las cuales cada enfoque domina.
Sobrecarga por trabajo y carga académica paralela.	Media	Alto	Hitos mensuales con entregables acotados; el alcance del mes 5 es el primer candidato a reducción si se acumula atraso.

9. Resultados esperados y contribución

- **Un escenario de simulación calibrado** de un corredor de Santiago, publicado como artefacto reutilizable, inexistente hoy en los benchmarks del área.
- **Evidencia cuantitativa y estadísticamente respaldada** del desempeño relativo de cinco estrategias de control sobre una red urbana latinoamericana, en cuatro regímenes de demanda.
- **Una caracterización de las condiciones** bajo las cuales el control aprendido justifica su complejidad frente a Max-Pressure, que es descentralizado, sin entrenamiento y con garantías teóricas.
- **Un repositorio reproducible** que permita a terceros regenerar cada resultado del informe.
- **Una discusión fundamentada sobre viabilidad de despliegue,** incluyendo requerimientos de instrumentación y la brecha entre los supuestos de observabilidad del modelo y la infraestructura efectivamente disponible en Santiago.

Referencias preliminares

Listado de partida, a ampliar durante la revisión bibliográfica del mes 1. Las referencias deben verificarse y normalizarse al formato exigido por la escuela antes de la entrega formal.

Ault, J., & Sharon, G. (2021). Reinforcement Learning Benchmarks for Traffic Signal Control. Proceedings of the 35th Conference on Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track.

Alegre, L. N. (2019). SUMO-RL: Reinforcement Learning environments for Traffic Signal Control with SUMO. Repositorio de software, licencia MIT. https://github.com/LucasAlegre/sumo-rl

Donatus, R. E., Ter, K., & Udekwe, D. (2025). Multi-Agent Reinforcement Learning in Intelligent Transportation Systems: A Comprehensive Survey. arXiv:2508.20315.

Lopez, P. A., Behrisch, M., Bieker-Walz, L., Erdmann, J., Flötteröd, Y.-P., Hilbrich, R., Lücken, L., Rummel, J., Wagner, P., & Wießner, E. (2018). Microscopic Traffic Simulation using SUMO. IEEE International Conference on Intelligent Transportation Systems (ITSC), 2575–2582.

Mnih, V., Kavukcuoglu, K., Silver, D., et al. (2015). Human-level control through deep reinforcement learning. Nature, 518(7540), 529–533.

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal Policy Optimization Algorithms. arXiv:1707.06347.

Varaiya, P. (2013). Max pressure control of a network of signalized intersections. Transportation Research Part C: Emerging Technologies, 36, 177–195.

Webster, F. V. (1958). Traffic Signal Settings. Road Research Technical Paper No. 39. Her Majesty's Stationery Office, Londres.

Wei, H., Chen, C., Zheng, G., Wu, K., Gayah, V., Xu, K., & Li, Z. (2019). PressLight: Learning Max Pressure Control to Coordinate Traffic Signals in Arterial Network. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining.

Wei, H., Xu, N., Zhang, H., Zheng, G., Zang, X., Chen, C., Zhang, W., Zhu, Y., Xu, K., & Li, Z. (2019). CoLight: Learning Network-level Cooperation for Traffic Signal Control. Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM).

Zhang, L., Wu, Q., Shen, J., Lü, L., Du, B., & Wu, J. (2022). Expression might be enough: representing pressure and demand for reinforcement learning based traffic signal control. Proceedings of the 39th International Conference on Machine Learning (ICML), PMLR 162.

SECTRA — Secretaría de Planificación de Transporte, Ministerio de Transportes y Telecomunicaciones de Chile. Encuesta Origen Destino de Viajes del Gran Santiago. https://www.sectra.gob.cl/

Unidad Operativa de Control de Tránsito (UOCT), Ministerio de Transportes y Telecomunicaciones de Chile. https://www.uoct.cl/

Eclipse SUMO. Documentación oficial: importación desde OpenStreetMap y calibración de demanda. https://sumo.dlr.de/docs/